

جلسه اول



بخش ۳: انواع اشیاء در R؛ داده‌های چارچوب‌دار

در پژوهش‌های واقعی، داده‌ها معمولاً به صورت یک مقدار منفرد یا یک بردار ساده ذخیره نمی‌شوند، بلکه در قالب یک جدول ثبت می‌شوند. برای مثال، در یک مطالعه رشد میگو ممکن است برای هر تکرار آزمایشی ستون‌هایی مانند شناسه استخر، تیمار، وزن اولیه، وزن نهایی، تعداد اولیه، تعداد نهایی، شوری، دما و اکسیژن محلول ثبت شود. در R، یکی از ساختارهای اصلی برای نگهداری این نوع داده‌های جدولی، `data.frame` است.



داده‌های چارچوب‌دار چیست؟

داده‌های چارچوب‌دار یا `data.frame` ساختاری جدولی در R هستند که در آن:

- هر سطر معمولاً یک مشاهده، نمونه، تکرار یا واحد آزمایشی است.
 - هر ستون یک متغیر پژوهشی است.
 - ستون‌ها می‌توانند نوع‌های متفاوتی داشته باشند؛ برای مثال یک ستون عددی، ستون دیگر متنی و ستون دیگر طبقه‌ای باشد.
- در علوم شیلات، آبریزان و میگو، مثال‌های رایج از داده‌های جدولی عبارت‌اند از:

- داده‌های رشد چند تکرار آزمایشی
- داده‌های کیفیت آب در ایستگاه‌های مختلف
- داده‌های زیست‌سنجی طول و وزن ماهیان
- داده‌های بقا در تیمارهای مختلف
- داده‌های ترکیب لاشه یا ترکیب شیمیایی خوراک
- داده‌های تراکم پلانکتون یا فراوانی گونه‌ها



چرا `data.frame` مهم است؟

بیشتر تحلیل‌های آماری، ترسیم نمودارها و مدل‌سازی‌ها در R بر پایه داده‌های جدولی انجام می‌شوند. اگر داده‌های پژوهشی شما در قالب `data.frame` منظم باشند، در مراحل بعدی می‌توانید:

- تحلیل توصیفی انجام دهید
- داده‌ها را فیلتر یا مرتب کنید
- آزمون‌های آماری اجرا کنید
- نمودارهای علمی ترسیم کنید
- مدل‌های آماری بسازید
- خروجی‌ها را برای مقاله یا گزارش آماده کنید

بنابراین `data.frame` یکی از بنیادی‌ترین اشیاء R برای تحلیل داده‌های پژوهشی است.

ساخت `data.frame` با داده‌های ساده

برای ساخت یک `data.frame` از تابع `data.frame()` استفاده می‌شود.

مثال زیر داده‌های ساده یک آزمایش رشد میگو را نشان می‌دهد:

```
shrimp_data <- data.frame(
  pond_id = c("P1", "P2", "P3", "P4"),
  treatment = c("Control", "Probiotic", "Control", "Probiotic"),
  initial_weight = c(2.1, 2.3, 2.0, 2.2),
  final_weight = c(15.2, 16.8, 14.9, 16.1),
  survival_rate = c(94, 96, 91, 95)
)
```

shrimp_data

خروجی به شکل یک جدول خواهد بود:

	pond_id	treatment	initial_weight	final_weight	survival_rate
1	P1	Control	2.1	15.2	94
2	P2	Probiotic	2.3	16.8	96
3	P3	Control	2.0	14.9	91
4	P4	Probiotic	2.2	16.1	95

در این جدول:

- هر سطر یک واحد مشاهده است.
- هر ستون یک متغیر پژوهشی است.

ویژگی‌های اصلی `data.frame`

یک `data.frame` چند ویژگی مهم دارد که پژوهشگر باید آن‌ها را به خوبی بشناسد.

هر ستون یک متغیر است

برای مثال در داده زیر:

- `pond_id` شناسه استخر
- `treatment` نوع تیمار
- `initial_weight` وزن اولیه
- `final_weight` وزن نهایی
- `survival_rate` درصد بقا

هر سطر یک مشاهده است

در مثال بالا، هر سطر می‌تواند یک استخر، یک تکرار یا یک واحد آزمایشی باشد.

ستون‌ها می‌توانند نوع متفاوت داشته باشند

برای مثال:

- `pond_id` متنی است
- `treatment` متنی یا طبقه‌ای است
- `initial_weight` عددی است
- `final_weight` عددی است
- `survival_rate` عددی است

این یکی از تفاوت‌های مهم `data.frame` با بردار است. در بردار همه عناصر باید هم‌نوع باشند، اما در `data.frame` هر ستون می‌تواند نوع خاص خود را داشته باشد.

طول همه ستون‌ها باید برابر باشد

در هنگام ساخت `data.frame`، تعداد عناصر همه ستون‌ها باید یکسان باشد. اگر یک ستون ۴ مقدار داشته باشد و ستون دیگر ۵ مقدار، R خطا می‌دهد.
نمونه نادرست:

```
data.frame(  
  pond_id = c("P1", "P2", "P3"),  
  final_weight = c(15.2, 16.8)  
)
```

بررسی کلاس داده

برای بررسی نوع شیء:

```
class(shrimp_data)
```

خروجی:

```
[1] "data.frame"
```

برای مشاهده ساختار کلی:

```
str(shrimp_data)
```

خروجی نمونه:

```
'data.frame':      4 obs. of  5 variables:
 $ pond_id      : chr  "P1" "P2" "P3" "P4"
 $ treatment    : chr  "Control" "Probiotic" "Control" "Probiotic"
 $ initial_weight: num  2.1 2.3 2 2.2
 $ final_weight : num  15.2 16.8 14.9 16.1
 $ survival_rate: num  94 96 91 95
```

برای پژوهشگر، `str()` یکی از سریع ترین و مفیدترین ابزارها برای بررسی ساختار داده است.



نام گذاری ستون ها

بهتر است هنگام ساخت `data.frame` نام ستون ها را به صورت دقیق و معنادار انتخاب کنید.
نمونه مناسب:

```
shrimp_data <- data.frame(
  pond_id = c("P1", "P2", "P3"),
  salinity = c(18, 20, 22),
  temperature = c(28.5, 29.0, 28.2)
)
```

نام های مناسب باید:

- کوتاه باشند
- معنادار باشند
- بدون فاصله باشند
- ترجیحاً با `_` نوشته شوند
- برای تحلیل و گزارش نویسی خوانا باشند

نمونه های مناسب:

```
initial_weight
final_weight
survival_rate
dissolved_oxygen
sampling_date
protein_level
```

نمونه های نامناسب:

```
final weight
x1
data_new2_final
my column
```

مشاهده نام ستون‌ها

برای مشاهده نام ستون‌ها:

```
names(shrimp_data)
```

تغییر نام ستون‌ها

اگر بخواهید نام ستون‌ها را تغییر دهید، می‌توانید از `names()` استفاده کنید.

```
shrimp_data <- data.frame(  
  x = c("P1", "P2", "P3"),  
  y = c(2.1, 2.3, 2.0),  
  z = c(15.2, 16.8, 14.9)  
)  
  
names(shrimp_data) <- c("pond_id", "initial_weight", "final_weight")  
  
shrimp_data
```

تغییر نام برخی ستون‌ها

اگر فقط بخواهید بعضی نام‌ها را عوض کنید:

```
names(shrimp_data)[2] <- "weight_initial"  
names(shrimp_data)[3] <- "weight_final"
```

در تحلیل‌های پژوهشی، بهتر است از ابتدا نام‌گذاری استاندارد و پایدار انتخاب شود تا در مراحل بعدی دچار سردرگمی نشوید.

ساخت یک `data.frame` واقعی‌تر برای داده‌های شیلاتی

مثال زیر داده‌های ساده کیفیت آب و رشد در چند استخر را نشان می‌دهد:

```
pond_data <- data.frame(  
  pond_id = c("P1", "P2", "P3", "P4", "P5"),  
  treatment = c("Control", "Control", "Probiotic", "Probiotic", "Probiotic"),  
  initial_weight = c(2.0, 2.1, 2.2, 2.3, 2.1),  
  final_weight = c(14.8, 15.1, 16.4, 16.9, 16.2),  
  temperature = c(28.4, 28.7, 29.1, 28.9, 28.6),  
  salinity = c(18, 19, 20, 20, 21),
```

```
dissolved_oxygen = c(5.6, 5.4, 5.9, 5.7, 5.8)
)
```

```
pond_data
```

	pond_id	treatment	initial_weight	final_weight	temperature	salinity
dissolved_oxygen						
1	P1	Control	2.0	14.8	28.4	18
5.6						
2	P2	Control	2.1	15.1	28.7	19
5.4						
3	P3	Probiotic	2.2	16.4	29.1	20
5.9						
4	P4	Probiotic	2.3	16.9	28.9	20
5.7						
5	P5	Probiotic	2.1	16.2	28.6	21
5.8						

این ساختار همان الگویی است که در بسیاری از پروژه‌های پژوهشی استفاده می‌شود: هر سطر یک واحد مشاهده و هر ستون یک متغیر.



ورود داده‌ها با `read.table()`

در پروژه‌های واقعی معمولاً داده‌ها از قبل در فایل ذخیره شده‌اند و پژوهشگر آن‌ها را از فایل وارد R می‌کند. یکی از توابع پایه برای خواندن داده‌های متنی جدولی، `read.table()` است.

این تابع برای فایل‌هایی مناسب است که به صورت متنی ذخیره شده‌اند؛ مانند:

- فایل‌های متنی ساده
- فایل‌های tab-delimited
- فایل‌های space-delimited
- فایل‌های متنی قابل صدور از Excel یا نرم‌افزارهای دیگر

ساختار کلی `read.table()`

ساختار پایه به شکل زیر است:

```
data_name <- read.table("file_name.txt", header = TRUE)
```

در اینجا:

- `"file_name.txt"` نام فایل ورودی است
- `header = TRUE` یعنی سطر اول فایل شامل نام ستون‌هاست

مثال ساده از `read.table()`

فرض کنید فایل متنی زیر وجود دارد:

```
pond_id treatment initial_weight final_weight
P1 Control 2.1 15.2
P2 Probiotic 2.3 16.8
P3 Control 2.0 14.9
P4 Probiotic 2.2 16.1
```

برای خواندن این فایل:

```
shrimp_data <- read.table("shrimp_data.txt", header = TRUE)

shrimp_data
```

استفاده از جداکننده‌ها در `read.table()`

گاهی داده‌ها با فاصله، گاهی با `tab` و گاهی با جداکننده دیگر ذخیره می‌شوند. در چنین حالتی باید جداکننده مناسب مشخص شود.

فایل `tab-delimited`

```
shrimp_data <- read.table("shrimp_data_t.txt", header = TRUE, sep = "\t")
```

فایل با جداکننده کاما

اگرچه برای فایل CSV معمولاً از `read.csv()` استفاده می‌شود، ولی می‌توان با `read.table()` نیز آن را خواند:

```
shrimp_data <- read.table("dataset/shrimp_data.csv", header = TRUE, sep = ",")
```

فایل با جداکننده نقطه ویرگول

```
shrimp_data <- read.table("dataset/shrimp_data_v.txt", header = TRUE, sep = ";")
```



نکات مهم در استفاده از `read.table()`

وجود نام ستون‌ها

اگر سطر اول فایل نام ستون‌ها باشد، باید `header = TRUE` تنظیم شود.

```
shrimp_data <- read.table("dataset/shrimp_data.txt", header = FALSE)
```

در این حالت R خودش نام‌هایی مانند V1 , V2 , V3 تولید می‌کند.

توجه به جداکننده

بسیاری از خطاهای ورود داده به دلیل تعیین نکردن جداکننده درست رخ می‌دهد. اگر بعد از ورود داده ببینید همه اطلاعات در یک ستون قرار گرفته‌اند، معمولاً مشکل از `sep` است.

توجه به مسیر فایل

اگر فایل در مسیر کاری جاری نباشد، باید مسیر دقیق فایل مشخص شود.

```
shrimp_data <- read.table("C:/Users/Hagbini/Desktop/R/shrimp_data.txt", header = TRUE)
```

در R بهتر است از `/` در مسیر فایل استفاده شود.

بررسی داده پس از ورود

بعد از خواندن داده، همیشه باید ساختار آن بررسی شود:

```
str(shrimp_data)
names(shrimp_data)
```

```
> str(shrimp_data)
'data.frame':   4 obs. of  4 variables:
 $ pond_id      : chr  "P1" "P2" "P3" "P4"
 $ treatment    : chr  "Control" "Probiotic" "Control" "Probiotic"
 $ initial_weight: num  2.1 2.3 2 2.2
 $ final_weight : num  15.2 16.8 14.9 16.1
> names(shrimp_data)
[1] "pond_id"      "treatment"    "initial_weight" "final_weight"
```

این کار به پژوهشگر کمک می‌کند تا مطمئن شود ستون‌ها درست خوانده شده‌اند.



ذخیره داده‌ها با `write.table()`

پس از ساخت، اصلاح یا آماده‌سازی داده‌ها، ممکن است لازم باشد آن‌ها را در فایل ذخیره کنید. تابع پایه برای این کار `write.table()` است.

ساختار کلی `write.table()`

```
write.table(data_name, file = "output.txt")
```

مثال ساده از ذخیره داده

```
write.table(pond_data, file = "pond_data_output.txt")
```

پس از اجرای این دستور، فایل متنی شامل جدول داده ساخته می‌شود.

ذخیره با نام ستون‌ها و بدون شماره سطر

در بسیاری از موارد بهتر است شماره سطرها ذخیره نشوند.

```
write.table(pond_data,  
            file = "pond_data_output.txt",  
            row.names = FALSE)
```

ذخیره با جداکننده `tab`

```
write.table(pond_data,  
            file = "pond_data_output.txt",  
            sep = "\t",  
            row.names = FALSE)
```

ذخیره با جداکننده کاما

```
write.table(pond_data,  
            file = "pond_data_output.csv",  
            sep = ",",  
            row.names = FALSE)
```



نکات مهم در write.table()

حذف شماره سطرها

در بیشتر فایل‌های خروجی پژوهشی بهتر است `row.names = FALSE` استفاده شود؛ زیرا شماره سطرها معمولاً بخشی از داده اصلی نیستند.

تعیین جداکننده مناسب

اگر فایل برای استفاده در Excel یا نرم‌افزار دیگر ذخیره می‌شود، باید جداکننده مناسب انتخاب شود.

- برای فایل متنی tab-delimited از `sep = "\t"`
- برای فایل CSV از `sep = ","`

ذخیره نسخه پاک‌سازی‌شده داده

در کار پژوهشی بهتر است پس از هر مرحله مهم، نسخه‌ای از داده ذخیره شود. برای مثال:

```
raw_data.txt  
clean_data.txt  
analysis_data.txt
```

این کار بازتولیدپذیری تحلیل را تقویت می‌کند.

مثال کوچک از ورود و ذخیره داده

فرض کنید داده اولیه‌ای را از فایل وارد کرده‌اید و فقط می‌خواهید نام ستون‌ها را استاندارد کنید و فایل را دوباره ذخیره نمایید.

```
trial_data <- read.table("trial_data.txt", header = TRUE, sep = "\t")  
  
names(trial_data) <- c("pond_id", "treatment", "initial_weight",  
"final_weight")  
  
write.table(trial_data,  
            file = "trial_data_clean.txt",  
            sep = "\t",  
            row.names = FALSE)
```

در این بخش عمده‌ای از ورود به جزئیات پردازش بیشتر داده‌ها خودداری می‌شود، زیرا تحلیل توصیفی و کار عملی بیشتر با `data.frame` در جلسه بعد بررسی خواهد شد.

خواندن داده‌های Excel در R

در عمل، بخش بزرگی از داده‌های پژوهشی در فایل‌های Excel ذخیره می‌شوند. برای خواندن فایل‌های Excel در R معمولاً از بسته `readxl` استفاده می‌شود.

نصب بسته

```
install.packages("readxl")
```

فعال‌سازی بسته

```
library(readxl)
```

خواندن فایل Excel

```
shrimp_data <- read_excel("dataset/shrimp_data.xlsx")
```

اگر فایل چند sheet داشته باشد، می‌توان sheet را مشخص کرد.

```
shrimp_data <- read_excel("dataset/shrimp_data.xlsx", sheet = 1)
```

یا با نام sheet:

```
shrimp_data <- read_excel("dataset/shrimp_data.xlsx", sheet = "GrowthData")
```

نکات مهم در خواندن فایل Excel

یکنواختی نام ستون‌ها

بهتر است در فایل Excel، سطر اول فقط شامل نام متغیرها باشد و سلول‌های ترکیبی، عنوان‌های چندسطری یا توضیحات اضافی در بالا وجود نداشته باشد.

هر ستون فقط یک نوع داده

برای مثال، در ستون وزن نباید هم عدد و هم متن‌هایی مانند `"missing"` یا `"bad sample"` وجود داشته باشد. در غیر این صورت ممکن است کل ستون به صورت متنی خوانده شود.

حذف رنگ، فرمول و قالب‌بندی غیر ضروری

در R معمولاً با محتوای سلول کار می‌کند، نه با ظاهر آن. بنابراین بهتر است فایل Excel برای تحلیل آماری تا حد ممکن ساده و منظم باشد.



خواندن داده‌های SPSS در R

برای خواندن فایل‌های SPSS معمولاً از بسته `haven` استفاده می‌شود.

نصب بسته

```
install.packages("haven")
```

فعال‌سازی بسته

```
library(haven)
```

خواندن فایل SPSS

```
fish_data <- read_sav("fish_data.sav")
```

نکات مهم درباره فایل‌های SPSS

فایل‌های SPSS ممکن است شامل برچسب‌های متغیر، برچسب‌های مقادیر و قالب‌های خاص باشند. هنگام ورود به R، باید ساختار داده را بررسی کنید تا مطمئن شوید متغیرها به شکل مناسب خوانده شده‌اند.

برای بررسی ساختار:

```
str(fish_data)
```

گاهی برخی متغیرهای طبقه‌ای به صورت برچسب‌دار وارد می‌شوند و در مراحل بعد لازم است برای تحلیل مناسب آماده‌سازی شوند. جزئیات این کار را در مراحل بعدی تحلیل داده بررسی خواهیم کرد.



نکات مهم برای آماده‌سازی فایل قبل از ورود به R

پیش از ورود داده به R، بهتر است چند اصل رعایت شود:

- هر سطر فقط یک مشاهده باشد.
- هر ستون فقط یک متغیر باشد.
- نام ستون‌ها کوتاه، واضح و بدون فاصله باشد.
- از وارد کردن واحد اندازه‌گیری در داخل سلول‌ها خودداری شود.
- داده عددی فقط به صورت عدد ذخیره شود.

- از سلول‌های خالی غیرمنطقی، سطرهای توضیحی و عنوان‌های چندسطری پرهیز شود.
 - کدگذاری تیمارها و گروه‌ها از ابتدا منظم باشد.
 - فایل خام همیشه بدون تغییر نگهداری شود.
- برای مثال، این شکل مناسب نیست:

Weight = 15.2 g

و این شکل مناسب است:

15.2

واحد اندازه‌گیری باید در نام متغیر، مستندات یا فایل توضیحی ثبت شود، نه در داخل مقدار داده.

تفاوت فایل خام و فایل تحلیلی

در پروژه‌های پژوهشی بهتر است حداقل دو نسخه از داده‌ها وجود داشته باشد:

- فایل خام: همان داده اولیه ثبت‌شده
- فایل تحلیلی: نسخه‌ای که برای تحلیل در R آماده شده است

نمونه نام‌گذاری:

shrimp_growth_raw.xlsx
shrimp_growth_analysis.txt

این شیوه در مستندسازی پژوهش و پاسخ‌گویی به داوران مقاله بسیار مفید است.

جدول توابع متداول مربوط به data.frame

تابع	کاربرد	نمونه
data.frame()	ساخت داده جدولی	data.frame(id = c("P1", "P2"), weight = c(15.2, 16.1))
class()	بررسی کلاس شیء	class(shrimp_data)
str()	مشاهده ساختار داده	str(shrimp_data)
names()	مشاهده یا تغییر نام ستون‌ها	names(shrimp_data)
read.table()	خواندن فایل متنی جدولی	read.table("data.txt", header = TRUE)
write.table()	ذخیره داده در فایل متنی	write.table(shrimp_data, file = "out.txt")

تابع	کاربرد	نمونه
read_excel()	خواندن فایل Excel	read_excel("data.xlsx")
read_sav()	خواندن فایل SPSS	read_sav("data.sav")

مثال: ورود و سازمان‌دهی داده‌های رشد و کیفیت آب

در یک مطالعه پرورش میگوی وانامی، داده‌های اولیه در یک فایل جدولی ثبت شده‌اند. هر سطر مربوط به یک استخر آزمایشی است و ستون‌ها شامل شناسه استخر، نوع تیمار، وزن اولیه، وزن نهایی، دما، شوری و اکسیژن محلول هستند. هدف این مرحله فقط ورود داده، بررسی ساختار و ذخیره نسخه منظم برای تحلیل جلسه بعد است.

```
pond_data <- data.frame(
  pond_id = c("P1", "P2", "P3", "P4", "P5", "P6"),
  treatment = c("Control", "Control", "Probiotic", "Probiotic", "Synbiotic",
"Synbiotic"),
  initial_weight = c(2.0, 2.1, 2.2, 2.3, 2.1, 2.2),
  final_weight = c(14.8, 15.1, 16.4, 16.9, 17.2, 17.0),
  temperature = c(28.4, 28.7, 29.1, 28.9, 29.0, 28.8),
  salinity = c(18, 19, 20, 20, 21, 21),
  dissolved_oxygen = c(5.6, 5.4, 5.9, 5.7, 6.0, 5.8)
)

write.table(pond_data,
  file = "pond_data_session1.txt",
  sep = "\t",
  row.names = FALSE)
```

خروجی در R

```
> class(pond_data)
[1] "data.frame"

> str(pond_data)
'data.frame':   6 obs. of  7 variables:
 $ pond_id      : chr  "P1" "P2" "P3" "P4" ...
 $ treatment    : chr  "Control" "Control" "Probiotic" "Probiotic" ...
 $ initial_weight : num  2 2.1 2.2 2.3 2.1 2.2
 $ final_weight  : num  14.8 15.1 16.4 16.9 17.2 17
 $ temperature   : num  28.4 28.7 29.1 28.9 29 28.8
 $ salinity      : num  18 19 20 20 21 21
 $ dissolved_oxygen: num  5.6 5.4 5.9 5.7 6 5.8

> names(pond_data)
```

```
[1] "pond_id"      "treatment"    "initial_weight" "final_weight"
"temperature"  "salinity"
[7] "dissolved_oxygen"
```

```
> head(pond_data)
  pond_id treatment initial_weight final_weight temperature salinity
dissolved_oxygen
1      P1   Control          2.0          14.8          28.4          18
5.6
2      P2   Control          2.1          15.1          28.7          19
5.4
3      P3 Probiotic          2.2          16.4          29.1          20
5.9
4      P4 Probiotic          2.3          16.9          28.9          20
5.7
5      P5 Synbiotic          2.1          17.2          29.0          21
6.0
6      P6 Synbiotic          2.2          17.0          28.8          21
5.8
```

در این مثال، داده‌ها در قالب `data.frame` ساخته شده‌اند، ساختار آن‌ها بررسی شده و یک نسخه منظم از فایل برای استفاده در جلسه دوم ذخیره شده است. در جلسه بعد، همین داده‌ها مبنای تحلیل توصیفی، خلاصه‌سازی آماری و آشنایی اولیه با توصیف کمی داده‌ها خواهند بود.



پروژه پایان جلسه اول

عنوان پروژه

آماده‌سازی داده‌های یک آزمایش پژوهشی برای ورود به تحلیل در R

صورت پروژه

اطلاعات یک آزمایش پژوهشی در حوزه شیلات، آبزیان یا میگو را به شکل صحیح در یکی از قالب‌های زیر وارد کنید:

- فایل Excel
- فایل TXT
- فایل CSV

سپس فایل داده را در R وارد کرده و موارد مهم دیتاست را بررسی کنید.

حداقل ساختار داده

داده باید حداقل شامل ۶ سطر و ۹ ستون باشد.

ستون‌های پیشنهادی:

- شناسه واحد آزمایشی

- تیمار
- وزن اولیه
- وزن نهایی
- تعداد اولیه
- تعداد نهایی
- دما
- شوری
- اکسیژن محلول

خروجی مورد انتظار

- فایل داده اولیه در قالب CSV یا Excel، TXT
- فایل وارد شده و بررسی شده در R
- گزارش کوتاه از وضعیت دیتاست شامل:
 - تعداد مشاهدات
 - تعداد متغیرها
 - نام متغیرها
 - نوع متغیرها
 - تعداد داده‌های گم شده
 - نام تیمارها یا گروه‌ها