

جلسه ۳ - بخش ۴: همبستگی و رگرسیون خطی

هدف بخش: در این بخش پژوهشگر یاد می‌گیرد رابطه بین دو یا چند متغیر کمی را در داده‌های پژوهشی شیلات، آبزیان و میگو بررسی کند؛ ابتدا با همبستگی شدت و جهت رابطه را بسنجد و سپس با رگرسیون خطی مقدار یک متغیر پاسخ را بر اساس یک یا چند متغیر پیش‌بین مدل‌سازی کند.

تفاوت همبستگی و رگرسیون

مفهوم	هدف	خروجی اصلی	مثال در شیلات
همبستگی	بررسی شدت و جهت رابطه بین دو متغیر	ضریب همبستگی و p-value	رابطه بین شوری آب و نرخ رشد میگو
رگرسیون خطی ساده	پیش‌بینی یک متغیر پاسخ با یک متغیر پیش‌بین	معادله خط، ضرایب، R-squared و p-value	پیش‌بینی وزن ماهی بر اساس طول
رگرسیون خطی چندگانه	پیش‌بینی پاسخ با چند متغیر پیش‌بین	اثر هم‌زمان چند عامل	پیش‌بینی رشد میگو با دما، شوری و اکسیژن

نکته مهم: همبستگی فقط می‌گوید دو متغیر با هم تغییر می‌کنند یا نه؛ اما رگرسیون یک مدل پیش‌بینی و تفسیر اثر ارائه می‌دهد.

داده‌های نمونه برای بخش

در این مثال، داده‌های رشد میگو در یک دوره پرورش فرضی بررسی می‌شود. متغیرهای اندازه‌گیری شده شامل دمای آب، شوری، اکسیژن محلول، طول و وزن نهایی میگو هستند.

```
shrimp_growth <- data.frame(
  temperature = c(27.1, 28.0, 28.5, 29.2, 30.0, 30.5, 31.0, 31.5, 32.0, 32.5,
    27.8, 28.6, 29.4, 30.2, 31.1, 31.8, 32.3, 29.8, 30.7, 28.9),
  salinity = c(22, 23, 24, 25, 26, 27, 28, 29, 30, 31,
    23, 24, 25, 26, 27, 28, 29, 25, 27, 24),
  dissolved_oxygen = c(6.8, 6.7, 6.5, 6.4, 6.2, 6.1, 5.9, 5.8, 5.7, 5.5,
    6.6, 6.5, 6.3, 6.1, 5.9, 5.8, 5.6, 6.2, 6.0, 6.4),
  length = c(8.1, 8.4, 8.7, 9.0, 9.2, 9.5, 9.7, 9.9, 10.0, 10.2,
    8.3, 8.6, 8.9, 9.3, 9.6, 9.8, 10.1, 9.1, 9.4, 8.8),
  weight = c(9.8, 10.5, 11.2, 12.1, 12.8, 13.4, 14.0, 14.5, 14.9, 15.3,
    10.3, 11.0, 11.9, 12.9, 13.8, 14.4, 15.1, 12.4, 13.2, 11.5)
)
```

```
head(shrimp_growth)
```

	temperature	salinity	dissolved_oxygen	length	weight
1	27.1	22	6.8	8.1	9.8
2	28.0	23	6.7	8.4	10.5
3	28.5	24	6.5	8.7	11.2
4	29.2	25	6.4	9.0	12.1
5	30.0	26	6.2	9.2	12.8
6	30.5	27	6.1	9.5	13.4

نمودار پراکنش برای بررسی اولیه رابطه

پیش از اجرای آزمون همبستگی یا رگرسیون، باید رابطه بین دو متغیر با نمودار پراکنش بررسی شود.


```
plot(shrimp_growth$length, shrimp_growth$weight,
  xlab = "Length",
  ylab = "Weight",
```

```

pch = 19,
col = "blue")

abline(lm(weight ~ length, data = shrimp_growth),
      col = "red",
      lwd = 2)

```



📌 تفسیر نمودار: اگر نقاط به صورت تقریبی در اطراف یک خط صعودی قرار گرفته باشند، رابطه مثبت خطی بین طول و وزن وجود دارد. اگر روند نزولی باشد، رابطه منفی است. اگر الگوی مشخصی دیده نشود، رابطه خطی ضعیف یا ناموجود است.

همبستگی پیرسون

همبستگی پیرسون زمانی استفاده می‌شود که هر دو متغیر کمی باشند و رابطه بین آن‌ها تقریباً خطی باشد.

کاربرد

📌 مثال: آیا بین طول و وزن نهایی میگو رابطه معنی‌دار وجود دارد؟

فرض‌ها

- هر دو متغیر کمی باشند.
- رابطه بین دو متغیر تقریباً خطی باشد.
- داده‌ها دارای پرت شدید نباشند.
- توزیع دو متغیر یا حداقل الگوی رابطه برای تحلیل پیرسون مناسب باشد.

فرض صفر و فرض مقابل

$$H_0 : \rho = 0$$

$$H_1: \rho \neq 0$$

در اینجا ρ ضریب همبستگی جامعه است.

اجرای آزمون در R

```
cor.test(shrimp_growth$length, shrimp_growth$weight,  
method = "pearson")
```

Pearson's product-moment correlation

```
data: shrimp_growth$length and shrimp_growth$weight  
t = 101.26, df = 18, p-value < 2.2e-16  
alternative hypothesis: true correlation is not equal to 0  
95 percent confidence interval:  
 0.9977332 0.9996611  
sample estimates:  
      cor  
0.9991234
```

🌸 نتیجه‌گیری: چون $p\text{-value} < 0.05$ است، فرض صفر رد می‌شود. بین طول و وزن میگو رابطه خطی معنی‌دار وجود دارد. مقدار مثبت و نزدیک به ۱ ضریب همبستگی نشان می‌دهد رابطه بسیار قوی و مستقیم است.

تفسیر ضریب همبستگی

ضریب همبستگی پیرسون با r نمایش داده می‌شود و مقدار آن بین -۱ و +۱ است.

$$-1 \leq r \leq 1$$

مقدار تقریبی r	شدت رابطه	تفسیر
نزدیک به ۰	بسیار ضعیف	رابطه خطی مشخص وجود ندارد
۰.۱ تا ۰.۳	ضعیف	رابطه کم
۰.۳ تا ۰.۵	متوسط	رابطه قابل توجه
۰.۵ تا ۰.۷	نسبتاً قوی	رابطه واضح
بالتر از ۰.۷	قوی	رابطه بسیار مشخص
نزدیک به ۱ یا -۱	بسیار قوی	رابطه تقریباً خطی کامل

🌸 نکته پژوهشی: معنی‌دار بودن آماری الزاماً به معنی اهمیت زیستی یا کاربردی نیست. در پژوهش‌های شیلات، مقدار اثر و تفسیر زیستی باید همراه با $p\text{-value}$ گزارش شود.

همبستگی اسپیرمن

اگر داده‌ها نرمال نباشند، رابطه خطی نباشد اما روند یکنواخت داشته باشد، یا داده‌ها رتبه‌ای باشند، از همبستگی اسپیرمن استفاده می‌شود.

کاربرد

🌸 مثال: آیا با افزایش شوری، وزن نهایی میگو به صورت یکنواخت افزایش می‌یابد؟

فرض‌ها

- متغیرها حداقل رتبه‌ای یا کمی باشند.
- رابطه بین دو متغیر یکنواخت باشد.
- نیاز جدی به نرمال بودن داده‌ها ندارد.
- نسبت به داده‌های پرت مقاوم‌تر از پیرسون است.


$$H_0 : \rho_s = 0$$

$$H_1 : \rho_s \neq 0$$

در اینجا ρ_s ضریب همبستگی رتبه‌ای اسپیرمن است.

نمودار مناسب

```
plot(shrimp_growth$salinity, shrimp_growth$weight,  
     xlab = "Salinity",  
     ylab = "Weight",  
     pch = 19,  
     col = "darkgreen")
```



اجرای آزمون در R

```
cor.test(shrimp_growth$salinity, shrimp_growth$weight,  
         method = "spearman")
```

خروجی خلاصه:

Spearman's rank correlation rho

data: shrimp_growth\$salinity and shrimp_growth\$weight
S = 11.042, p-value < 2.2e-16

alternative hypothesis: true rho is not equal to 0

sample estimates:

rho

0.9916974

🌸 نتیجه‌گیری: چون $p\text{-value} < 0.05$ است، رابطه رتبه‌ای معنی‌دار بین شوری و وزن میگو وجود دارد. مقدار مثبت ضریب اسپیرمن نشان می‌دهد با افزایش شوری، وزن نهایی نیز در این داده‌ها افزایش یافته است.

ماتریس همبستگی برای چند متغیر

وقتی چند متغیر کمی وجود دارد، می‌توان ماتریس همبستگی را برای بررسی اولیه روابط استفاده کرد.

```
cor(shrimp_growth)
```

	temperature	salinity	dissolved_oxygen	length	weight
temperature	1.0000000	0.9770534	-0.9940614	0.9943990	0.9958072
salinity	0.9770534	1.0000000	-0.9788717	0.9826908	0.9822243
dissolved_oxygen	-0.9940614	-0.9788717	1.0000000	-0.9889552	-0.9898355
length	0.9943990	0.9826908	-0.9889552	1.0000000	0.9991234
weight	0.9958072	0.9822243	-0.9898355	0.9991234	1.0000000

برای گرد کردن خروجی:

```
round(cor(shrimp_growth), 2)
```


	temperature	salinity	dissolved_oxygen	length	weight
temperature	1.00	0.98	-0.99	0.99	1.00
salinity	0.98	1.00	-0.98	0.98	0.98
dissolved_oxygen	-0.99	-0.98	1.00	-0.99	-0.99
length	0.99	0.98	-0.99	1.00	1.00
weight	1.00	0.98	-0.99	1.00	1.00

🌸 تفسیر: در این داده‌ها، وزن میگو با طول، دما و شوری رابطه مثبت دارد، اما با اکسیژن محلول رابطه منفی دیده می‌شود. این تفسیر باید با دانش زیستی و طراحی آزمایش بررسی شود، زیرا همبستگی بالا همیشه به معنی رابطه علی نیست.

نمودار ماتریس پراکنش

برای مشاهده هم‌زمان روابط بین چند متغیر کمی از نمودار ماتریس پراکنش استفاده می‌شود.

```
pairs(shrimp_growth,  
      pch = 19,  
      col = "blue")
```



📌 کاربرد نمودار: این نمودار کمک می‌کند رابطه‌های خطی، غیرخطی، داده‌های پرت و خوشه‌بندی احتمالی بین متغیرها بررسی شود.

رگرسیون خطی ساده

رگرسیون خطی ساده زمانی استفاده می‌شود که بخواهیم یک متغیر پاسخ کمی را بر اساس یک متغیر پیش‌بین کمی مدل‌سازی یا پیش‌بینی کنیم.

📌 مثال: پیش‌بینی وزن نهایی میگو بر اساس طول بدن.

مدل رگرسیون خطی ساده به‌صورت زیر است:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

در این مدل:

نماد	مفهوم
Y_i	متغیر پاسخ؛ وزن میگو
X_i	متغیر پیش‌بین؛ طول میگو
β_0	عرض از مبدأ
β_1	شیب خط رگرسیون
ε_i	خطای تصادفی

اجرای مدل رگرسیون خطی ساده

```
model_simple <- lm(weight ~ length, data = shrimp_growth)

summary(model_simple)
```

خروجی خلاصه:

Call:
lm(formula = weight ~ length, data = shrimp_growth)

```

Residuals:
    Min       1Q   Median       3Q      Max
-0.12225 -0.05337 -0.01102  0.05378  0.13082

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -12.1144     0.2461  -49.23   <2e-16 ***
length       2.6939     0.0266  101.26   <2e-16 ***
---
Signif. codes:
  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.07238 on 18 degrees of freedom
Multiple R-squared:  0.9982, Adjusted R-squared:  0.9982
F-statistic: 1.025e+04 on 1 and 18 DF, p-value: < 2.2e-16

```

معادله مدل

بر اساس خروجی بالا:

$$\widehat{Weight} = -12.1144 + 2.6939 \times Length$$

✿ تفسیر شیب: به ازای افزایش یک واحد در طول میگو، وزن نهایی به طور متوسط حدود 2.6939 واحد افزایش می یابد.

✿ تفسیر p-value مربوط به شیب: چون $p\text{-value} < 0.05$ است، اثر طول بر وزن معنی دار است.

✿ تفسیر R-squared: مقدار $R\text{-squared} = 0.9982$ یعنی حدود ۹۹.۸۲٪ از تغییرات وزن میگو توسط طول توضیح داده می شود.

فرضیه ها در رگرسیون خطی ساده

برای بررسی معنی داری اثر متغیر پیش بین، فرضیه مربوط به شیب مدل بررسی می شود.

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

اگر $\beta_1 = 0$ باشد، یعنی متغیر پیش بین رابطه خطی معنی داری با پاسخ ندارد.

✿ قاعده تصمیم: اگر $p\text{-value}$ مربوط به متغیر length کمتر از ۰.۰۵ باشد، فرض صفر رد می شود و اثر طول بر وزن معنی دار گزارش می شود.

بررسی مفروضات رگرسیون خطی

رگرسیون خطی فقط با معنی دار بودن $p\text{-value}$ کافی نیست. باید مفروضات مدل نیز بررسی شوند.

مفروضات اصلی

مفروضه	مفهوم	روش بررسی
خطی بودن	رابطه پاسخ و پیش بین خطی باشد	نمودار پراکنش و Residuals vs Fitted
نرمال بودن باقی مانده ها	خطاها تقریباً نرمال باشند	Q-Q plot و Shapiro-Wilk
همگنی واریانس	پراکندگی خطاها ثابت باشد	Scale-Location و Residuals vs Fitted
استقلال خطاها	مشاهدات مستقل باشند	طراحی آزمایش و ترتیب زمانی
نبود داده پرت اثر گذار	یک مشاهده مدل را بیش از حد تحت تأثیر قرار ندهد	Residuals vs Leverage و Cook's distance


نمودارهای تشخیصی مدل

```

par(mfrow = c(2, 2))
plot(model_simple)

```

```
par(mfrow = c(1, 1))
```



نمودار	کاربرد	وضعیت مطلوب
Residuals vs Fitted	بررسی خطی بودن و همگنی واریانس	پراکندگی تصادفی بدون الگوی مشخص
Normal Q-Q	بررسی نرمال بودن باقی‌مانده‌ها	قرار گرفتن نقاط نزدیک خط
Scale-Location	بررسی ثبات واریانس	پراکندگی تقریباً یکنواخت
Residuals vs Leverage	شناسایی نقاط اثرگذار	نبودن نقاط با اهرم و Cook بالا

📌 نکته: اگر در نمودار **Residuals vs Fitted** الگوی خمیده دیده شود، مدل خطی ساده ممکن است مناسب نباشد. اگر پراکندگی باقی‌مانده‌ها با افزایش مقدار برازش شده زیاد شود، مشکل ناهمگنی واریانس مطرح است.

آزمون نرمال بودن باقی‌مانده‌ها

```
shapiro.test(residuals(model_simple))
```

خروجی خلاصه:


Shapiro-Wilk normality test

data: residuals(model_simple)
W = 0.97274, p-value = 0.8114

📌 نتیجه‌گیری: چون $p\text{-value} > 0.05$ است، شواهد کافی علیه نرمال بودن باقی‌مانده‌ها وجود ندارد. بنابراین مفروضه نرمال بودن باقی‌مانده‌ها قابل قبول است.

بررسی باقی‌مانده‌ها با نمودار



```
hist(residuals(model_simple),  
     xlab = "Residuals",  
     main = "Histogram of residuals",  
     col = "gray80")
```



✳️ تفسیر: هیستوگرام باید تقریباً زنگوله‌ای باشد و در نمودار Q-Q نقاط باید نزدیک خط قرمز قرار گیرند.

```
qqnorm(residuals(model_simple))  
qqline(residuals(model_simple), col = "red", lwd = 2)
```

Normal Q-Q Plot



📌 تفسیر: نمودار Q-Q نقاط باید نزدیک خط قرمز قرار گیرند.

رگرسیون خطی چندگانه

رگرسیون خطی چندگانه زمانی استفاده می‌شود که یک متغیر پاسخ کمی با چند متغیر پیش‌بین کمی یا کیفی مدل‌سازی شود.

📌 مثال: پیش‌بینی وزن نهایی میگو بر اساس دما، شوری و اکسیژن محلول.

مدل کلی:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \varepsilon_i$$

در این مثال:

$$Weight_i = \beta_0 + \beta_1 Temperature_i + \beta_2 Salinity_i + \beta_3 DissolvedOxygen_i + \varepsilon_i$$

اجرای رگرسیون خطی چندگانه

```
model_multiple <- lm(weight ~ temperature + salinity + dissolved_oxygen,  
  data = shrimp_growth)
```

```
summary(model_multiple)
```

Call:

```
lm(formula = weight ~ temperature + salinity + dissolved_oxygen,  
  data = shrimp_growth)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.24113	-0.12118	0.04483	0.08884	0.19919

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-24.99835	11.06300	-2.260	0.038148 *
temperature	0.98054	0.19577	5.009	0.000129 ***
salinity	0.15493	0.06608	2.345	0.032281 *
dissolved_oxygen	0.68889	0.86508	0.796	0.437499

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1447 on 16 degrees of freedom

Multiple R-squared: 0.9938, Adjusted R-squared: 0.9926

F-statistic: 851 on 3 and 16 DF, p-value: < 2.2e-16

📌 تفسیر کاربردی: اگر p-value متغیر temperature کمتر از ۰.۰۵ باشد، اثر دما بر وزن نهایی میگو با کنترل اثر شوری و اکسیژن معنی دار است.

فرضیه‌ها در رگرسیون چندگانه آزمون کلی مدل

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0$$

تسین رفص ربارب بی‌ارض زا یکی لقادح : H_1

📌 اگر p-value کلی مدل کمتر از ۰.۰۵ باشد، مدل رگرسیونی از نظر آماری معنی دار است.

آزمون هر ضریب

برای هر متغیر پیش‌بین:

$$H_0 : \beta_j = 0$$

$$H_1 : \beta_j \neq 0$$

📌 اگر p-value مربوط به یک متغیر کمتر از ۰.۰۵ باشد، آن متغیر با ثابت بودن سایر متغیرها اثر معنی دار بر پاسخ دارد.

پیش‌بینی با مدل رگرسیون

پس از برازش مدل، می‌توان برای مشاهدات جدید پیش‌بینی انجام داد.

📌 مثال: پیش‌بینی وزن نهایی میگو با طول 9.5 .

```
new_shrimp <- data.frame(  
  length = c(9.5)  
)  
  
predict(model_simple, newdata = new_shrimp)
```

خروجی خلاصه:

1
13.47734

📌 تفسیر: بر اساس مدل خطی ساده، وزن مورد انتظار برای میگوی با طول 9.5 حدود ۱۳.۴۷ واحد است.

پیش‌بینی با بازه اطمینان

```
predict(model_simple, newdata = new_shrimp,
        interval = "confidence")
```

خروجی خلاصه:

	fit	lwr	upr
	13.47734	13.44014	13.51455

پیش‌بینی با بازه پیش‌بینی

```
predict(model_simple, newdata = new_shrimp,
        interval = "prediction")
```

	fit	lwr	upr
1	13.47734	13.32079	13.63389

🌸 تفسیر: بازه پیش‌بینی معمولاً از بازه اطمینان پهن‌تر است، زیرا عدم قطعیت مربوط به یک مشاهده جدید را نیز در نظر می‌گیرد.

مقایسه مدل‌ها

گاهی پژوهشگر می‌خواهد بداند آیا افزودن متغیر جدید باعث بهبود معنی‌دار مدل می‌شود یا نه.

```
model_temp <- lm(weight ~ temperature, data = shrimp_growth)

model_temp_sal <- lm(weight ~ temperature + salinity, data = shrimp_growth)

anova(model_temp, model_temp_sal)
```

خروجی خلاصه:

Analysis of Variance Table

Model 1: weight ~ temperature

Model 2: weight ~ temperature + salinity

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	18	0.45029				
2	17	0.34842	1	0.10187	4.9705	0.03956 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

🌸 نتیجه‌گیری: چون $p\text{-value} < 0.05$ است، افزودن متغیر شوری باعث بهبود معنی‌دار مدل نسبت به مدل فقط با دما شده است.

گزارش نویسی نتایج همبستگی

برای گزارش همبستگی در مقاله یا پایان‌نامه، باید نوع آزمون، مقدار ضریب همبستگی، جهت رابطه و $p\text{-value}$ ذکر شود.

نمونه گزارش

📊 بین طول و وزن نهایی میگو رابطه مثبت و معنی‌دار مشاهده شد. نتیجه آزمون همبستگی پیرسون نشان داد که این رابطه بسیار قوی است ($r = 0.998$, $p < 0.001$). بنابراین، با افزایش طول بدن، وزن نهایی میگو نیز افزایش می‌یابد.

گزارش نویسی نتایج رگرسیون

برای گزارش رگرسیون باید معادله مدل، معنی داری ضرایب، مقدار R^2 و وضعیت مفروضات بیان شود.

نمونه گزارش

📄 مدل رگرسیون خطی ساده برای پیش بینی وزن نهایی میگو بر اساس طول بدن معنی دار بود ($p\text{-value} < 0.001$). مقدار $R^2 = 0.9989$ نشان داد که حدود ۹۹.۸۹٪ تغییرات وزن توسط طول بدن توضیح داده می شود. شیب مدل مثبت و معنی دار بود، بنابراین افزایش طول بدن با افزایش وزن نهایی همراه است.